

Audio Annotation QA — Self-Study Guide

話者分離（Diarization）と音声キャプション（Audio Captioning）の品質保証

独自に作成した学習用教材。一般に公開された音響・言語学・アノテーションの知識に基づき、特定プロジェクトの機密情報は含みません。 — Kazuma Sasaki

目次

1. QAの基本姿勢（マインドセット）
2. Diarization の原理とチェック観点
3. Audio Captioning の原理とチェック観点
4. 話者・声の記述
5. 感情・声の届け方タグ
6. 採点の考え方（Major / Minor）
7. クイック・チェックリスト
8. 用語集（声・音の記述語）
9. 自己テスト

1. QAの基本姿勢

音声アノテーションのQAは「なんとなく変」を排除し、誰が読んでも同じ判断に至る客観的な基準で良し悪しを決める仕事。指摘は必ず「どのルールに、どう違反し、どう直すか」までセットにする。

3つの原則

- ・ 耳を最優先する：映像の見た目に引っ張られない。聞こえた事実だけを扱う。
- ・ 推測しない：確信が持てないものは「不明」と印を付ける。当て推量はモデルの幻覚（hallucination）の原因になる。
- ・ 一貫性：同じ現象は最初から最後まで同じルールで処理する。

2. Diarization の原理とチェック観点

Diarization＝「いつ・誰が・何を話したか」を時間軸に沿って正確に書き起こす作業。QAは次の4点を見る。

2-1. 転写の正確さ

- ・実際に発話された語と一致しているか（短縮形・省略・言い淀みの扱いが一貫しているか）
- ・幻覚（聞こえていない語の捏造）が無い／明らかに聞こえる語の欠落が無い
- ・笑い・咳などの非言語音が、決めたルールで一貫して記述されているか
- ・本当に聞き取れない箇所は、推測せず「不明瞭」として印を付けているか

判断の閾値：数回聞いても語として高い確信が持てないなら「不明瞭」。背景で何か聞こえる気がする程度なら、そもそも転写しない（＝幻覚を作らない）。

2-2. タイムスタンプの精度

- ・映像のフレームではなく「音」に合わせる。口の動きと音はズレることがある
- ・開始・終了の両方を厳密に。業界の実務では概ね $\pm 100\text{ms}$ 程度の精度が求められる
- ・スキュー（全体が一定量ずれる現象）に注意。1箇所直すだけでなく全体を点検する
- ・同一話者の区間は重ならない（意図的なミックスを除く）

2-3. 話者・発話源の帰属

- ・各発話が正しい話者に、最初から最後まで一貫して割り当てられているか
- ・画面内 / 画面外（同じ空間にいる） / ナレーション（別空間からの声）を区別できているか
- ・誰の声か特定できない群衆・同時発話は、決めたルール（例：「割り当て不可」）で処理しているか

画面内・外の見分け方（一例）：「今カメラをその場で一回転させたら、この話者は映るか？」
→ 映る＝同じ空間の画面外、映らない＝別空間のナレーション。

2-4. Diarization のよくある間違い

間違い	なぜ問題か
映像（口の動き）にタイムスタンプを合わせる	音とテキストがズレ、学習信号が劣化
聞こえない語を推測で埋める	幻覚を教え込む
非言語音の表記がバラバラ（laughs / laughing 混在）	一貫性が崩れる
話者の割り当てが途中で入れ替わる	話者識別の学習を壊す

不明瞭区間を細切れに分割

連続した不明瞭は一塊で扱うべき

3. Audio Captioning の原理とチェック観点

Audio Captioning＝動画内のあらゆる音（音楽・効果音・環境音・無音）を、聞こえた通りに構造化して記述する作業。発話はdiarization側で扱い、こちらには混ぜない。

3-1. 区切りの原則

- ・ 1つの「distinct sound（独立した音）」につき1キャプション
- ・ 連続音（途切れない太鼓のロール等）は1つ。同じ音でも別々に2回鳴れば2つ
- ・ 複数の音が重なるなら、それぞれにキャプションを作る（タイムスタンプは重なってよい）。開始時刻順に並べる

3-2. 「源を名指す前に、音そのものを描く」

最優先は音の性質・質感・振る舞いの描写。源（source）が分かれば名指すが、名詞は描写の入口であって結論ではない。「銃声」と書くだけでは不十分——どう鳴ったかを描く。

聞く手順：①映像より先に音だけを聞く ②複数回聞く（初回で細部は聞き逃す） ③下の5次元のうち、意味のあるものだけを使って描写する（全項目を埋めるのが目的ではない）。

3-3. 音を描く5つの次元

次元	見るもの	語の例
Pitch / Frequency	高さ。音程がある音は pitch、無い音（衝撃音・ノイズ）は周波数帯で	high, mid, low, rising, falling
Volume	音量と、その変化の有無	soft, moderate, loud, consistent, variable
Behaviour / Movement	時間的にどう始まり・続き・終わるか。反復・リズム	constant, swells, fades, pulses, sharp onset, sustained
Spatial position	近い/遠い、乾いた/反響、定位	dry, reverberant, echoey, close, distant
Overall quality	録音の劣化や不自然な加工（良いときは書かない）	distorted, clipped, muffled, tinny, glitchy

3-4. 良い記述・悪い記述（自作例）

題材：オフカメラのガラスが割れる音

✗ 少なすぎ：「画面外でガラスが割れる音、中音量」

✓ 良い：「画面外で鋭く明るい破碎音が一度鳴り、続いて細かな破片が散らばる短い余韻。中

音量で、わずかに反響する」

✕ 多すぎ：周波数やdB、RT60など技術数値の羅列（過剰で読み手に役立たない）

3-5. 発生源（Primary Source）の特定

- すべての音の源を判定し、画面内 / 画面外 / 環境音（ambient）を明示する
- 音楽も同様に、源が見えるか（ラジオ・ピアノ等）/ 見えないか/背景かを示す
- 過度に具体化しない（ネットが見えるからと「バレーボール」と断定せず「ボール」で留める等）
- 個々を特定できない多数の音は「群衆／集合」として環境音的に扱う

3-6. タイムスタンプと無音

- 音が聞こえ始めた時点から、聞こえなくなる時点まで。フェードインはフェードの開始から
- 実務では概ね $\pm 200\text{ms}$ 程度の精度
- 「コンピュータテスト」：音量を上げた静かな環境でも聞こえない音は、小さすぎるので注釈しない（幻覚回避）
- 無音は「予期に反する無音」のときだけ注釈する

4. 話者・声の記述

4-1. 視覚的記述（見える話者）

- ・ 目的は「人を区別できること」。年齢層・性別・身体的特徴・服装が基本要素
- ・ 断定できない属性（性別・人種など）は推測せず、他の特徴で区別する
- ・ 肌の色は段階表現（淡い～濃い）で。人種カテゴリーの決めつけはしない
- ・ 場所・位置は、それが識別に本当に役立つときだけ使う

4-2. 声の記述（見えない話者でも可）

- ・ できる限りピッチとアクセント／地域を含める
- ・ 同じ記述を2人に使わない。似た声はピッチや質感で差をつける
- ・ 声の記述に感情を混ぜない（「がっかりした声」は感情側のタグ）
- ・ 知らない情報を書かない（「アクセント不明」等の空振りを避ける）

5. 感情・声の届け方タグ

- ・ 声を分析する。映像で判断しない（見た目が怒っていても、声が平静ならNeutral）
- ・ デフォルトはNeutral。明確に支持できないなら付けない（過剰タグを避ける）
- ・ 1つのタグの付けすぎに注意。タスク全体で一貫させる
- ・ 感情（happy, angry, sad…）と、声の届け方（whispering, shouting, flat…）は別物として扱う

6. 採点の考え方

欠陥をMajorとMinorに分け、Majorが無く、Minorが無視できる水準のときだけ合格とする。

区分	例
Major（学習信号を壊す）	タイムスタンプの誤り、話者の誤割り当て、明確に聞こえる語の欠落／捏造、源の取り違え、誤訳
Minor（軽微）	文法・句読点の小さな誤り、記述の軽い過剰、タグのわずかな付けすぎ

7. クイック・チェックリスト

領域	確認
転写	☐ 幻覚なし ☐ 欠落なし ☐ 非言語音が一貫 ☐ 不明瞭は推測せず印
時刻	☐ 音基準 ☐ ±100ms ☐ スキューなし ☐ 同一話者の重なりなし
話者	☐ 帰属が一貫 ☐ 画面内/外/ナレーション区別 ☐ 群衆ルール適用
音記述	☐ 1音1キャプション ☐ 5次元のうち必要なもので描写 ☐ 源と ambient を明示
音時刻	☐ フェード開始から ☐ ±200ms ☐ 小さすぎる音は注釈しない
記述	☐ 話者を区別可能 ☐ 声に感情を混ぜない ☐ 曖昧語・推測なし
タグ	☐ 声で判断 ☐ 既定Neutral ☐ 過剰タグなし

8. 用語集（声・音の記述語）

カテゴリ	語
ピッチ	high / mid / low / monotone（変化が乏しい） / varied
速さ・区切り	fast / slow / choppy（途切れる） / smooth / hesitant
音色・質	breathy（息混じり） / hoarse（しゃがれ） / nasal（鼻に抜ける） / resonant（よく響く） / raspy（ざらつく） / booming（轟く） / squeaky（甲高い） / warm（温かい）
滑舌	well-enunciated / mumbled（こもる） / crisp（明瞭） / slurred（不明瞭）
抑揚	rising / falling / flat / melodic
その他	paused / vocal fry（きしむ低音） / tremulous（震える）
音の振る舞い	constant / swells / fades / pulses / builds / sharp onset / sustained
空間	dry / reverberant / echoey / close / distant

※ falsetto 等の音楽用語は声の記述に使わないのが一般的。

9. 自己テスト

Q1. 口の動きと音がわずかにズレている。タイムスタンプはどちらに合わせる？

Q2. 背景で何か言っている気がするが、語として聞き取れない。どう扱う？（2パターン：語だと分かるが内容不明 / そもそも語か不明）

Q3. 同じドアのノック音が、間を置いて2回鳴った。キャプションはいくつ？

Q4. 「画面外でガラスが割れる音、大きい」——このキャプションの問題点は？

Q5. 話者は見た目が怒っているが、声は淡々としている。感情タグは？

Q6. 「がっかりした低い声」——声の記述としてどこが不適切？

Q7. Major と Minor、それぞれ2つずつ挙げよ。

解答の要点

A1. 音。 A2. 語と分かるが内容不明＝「不明瞭」と印／語か不明＝注釈しない（幻覚回避）。
A3. 2つ（連続でないため）。 A4. 源の描写止まりで、音そのもの（質感・余韻・反響）が描けていない。 A5. Neutral（声で判断）。 A6. 「がっかり」は感情で、声の記述に混ぜてはいけない。 A7. Major＝時刻ズレ/話者誤り 等、Minor＝句読点/軽い過剰記述 等。