

Kazuma Sasaki — Playbook

Audio Data Quality ・ Diarization & Audio Captioning ・ Multilingual Annotation QA
kazmike.s@gmail.com ・ [linkedin.com/in/kazumasasaki](https://www.linkedin.com/in/kazumasasaki) ・ Tokyo

このドキュメントは、自分の事業を組み立てるための個人用マスター資料です。
Part 1～2（プロフィール／サービス）は顧客に見せる用、Part 3～4（戦略／ツール）は自分用。
中身はすべてオリジナル。守秘義務のある特定プロジェクトの内容・形式・事例は一切含みません。

目次

1. Professional Profile & QA Methodology（顧客用）
2. Service Offering & Pricing（顧客用）
3. 事業戦略 & ¥1億ロードマップ（自分用）
4. 営業ツールキット：LinkedIn / DM / レポート雛形 / ターゲット（自分用）

1. Professional Profile & QA Methodology

Who I am

2+ years in AI training data. Most recently a QA lead on a frontier AI lab's multimodal audio project, where I grew from trainer → pre-completion reviewer → post-completion reviewer → QA lead. I have reviewed at frontier-lab quality bars, trained annotators, and built review pipelines from scratch — in Japanese and English.

How I audit audio/video annotation — five layers

Each layer has a clear pass/fail bar, so feedback is specific and actionable — never "this feels off."

1. Transcription accuracy

- Words match what is actually said; contractions, elisions and fillers handled consistently
- No invented words (hallucinations); no dropped words that are clearly audible
- Non-speech sounds handled by a consistent rule, not ad hoc
- Genuinely unclear audio marked as such rather than guessed

2. Timestamp precision

- Start/end times aligned to the audio, not the video frame
- Tight tolerance (~100ms on speech, ~200ms on sound events)
- No drift / skew accumulating across a clip
- Same-speaker segments never overlap unless intentionally mixed

3. Speaker / source attribution

- Every utterance attributed to the correct speaker, consistently across the clip
- On-screen vs. off-screen vs. narration distinguished correctly
- Sound sources identified (which object, instrument or person produced it)
- Crowds / un-attributable sounds handled by a defined rule, not a guess

4. Descriptions (speaker + sound)

- Speaker profiles distinct enough to tell people apart unambiguously
- Voice descriptions capture pitch, accent/region and texture — without smuggling in emotion

- Sound descriptions convey how the sound actually is (character, volume, movement, space), not just a one-word label
- Descriptions avoid hedging and unverifiable claims

5. Tags (emotion + delivery)

- Tags supported by the audio, not by what the speaker looks like on screen
- Conservative by default — neutral unless the signal is clear
- No over-tagging of any single category; consistent across the whole task

How I score

I separate major issues (things that corrupt the training signal — wrong timestamps, wrong speaker, missing/invented words) from minor issues (grammar, light over-description). A task passes only when there are no major issues and minor ones are negligible.

What you get

A structured report per batch: per-item findings, the rule each one violated, and the specific fix — written so an annotator can act on it without a meeting. Fewer review rounds, a measurably cleaner dataset.

2. Service Offering & Pricing

What I do

- Multilingual speech data creation (core) — full annotation built from scratch: transcription, word-level diarization, speaker/voice profiling, emotion/delivery tagging. Production-ready data for ASR / TTS / voice agents.
- Audio captioning (specialty) — detailed description of all non-speech sound (music, SFX, ambient, silence) for multimodal audio understanding. Few suppliers at frontier-lab quality.
- Data QA (audit + report) — review your annotation data, return a structured report of findings, rules and fixes.
- Pipeline consulting / gold sets — design guidelines, error taxonomy, scoring rubric, reviewer workflow; build benchmark reference sets.

主力は「日本語・アジア言語のスピーチデータ作成」（需要最大・競合少・母国語の強み）。audio captioning を差別化の武器に。QA は入口。

Where I’m strongest

- Speaker diarization — word-level, ~100ms timestamp accuracy
- Audio captioning — music, sound effects, ambient sound, silence
- Speaker & voice profiling — pitch, accent, vocal texture
- Emotion / delivery tagging — conservative, audio-grounded
- Multilingual review (Japanese, English)

How we start

A free QA audit on a small sample of your data. You see exactly what I catch and how I report it, then decide whether to scope further. No commitment.

Engagement options

Service	Best for	Indicative rate
Full annotation + QA	Training data for ASR / TTS / voice agents	from \$30 / audio-minute
Audio captioning	Multimodal audio understanding	scoped (premium specialty)
QA / review only	Checking an existing pipeline	from \$1-6 / audio-minute
Pipeline consulting	Guideline / rubric design	from \$100 / hour

Project / retainer	Large or ongoing programs	scoped per engagement
--------------------	---------------------------	-----------------------

Rates are starting points and depend on language mix, turnaround and volume. Asian-language work is priced at a premium.


単価の考え方（自分用メモ）

売るもの	1分あたり	メモ
フルアノテーション	\$20-50	\$30で時給換算 約\$90（現\$38の2.4倍）。マージン約67%
QAのみ	\$1-6	速い＝安い。入口・関係作り用
アジア言語	上乗せ	供給不足＝プレミアム

¥1億換算：フル\$30/分なら約360時間分の音声、QA\$3/分なら約3,600時間分。フルで売る方が少量で¥1億に届く＝管理が楽。公開時は「from \$30/min」or プロジェクト見積で。

3. 事業戦略 & ￥1億ロードマップ （自分用）

バリューチェーンのどこに立つか



核心：OpenAI直は現実的に無理（実績ある法人ベンダーとしか契約しない）。そして、OpenAI直でなくても￥1億は作れる。だからそこに固執しない。

「誰から受けるか」－ 実現可能な順

段階	受注元	なぜ
① 今すぐ	ラボを通さない直接客（音声AIスタートアップ／国産AI企業／国策AIデータ事業）	小規模だから個人・小法人とも契約してくれる。実績を作る場所
② 中期	大手ベンダーの下請け（Scale / Surge / Mercor）	既に￥億のラボ契約を持ち、高品質な多言語キャパを常に欲しがる。日本語スライスを取る
③ 長期	フロンティアラボと直接	”次のmicro1”になる。法人・実績・キャパが揃って初めて

単発￥1億の本命：日本の国策AIデータ事業

- ・ 政府が国産LLM・日本語AIに資金を流しており、「高品質な日本語音声データ」はまさに発注対象
- ・ 自分の武器（日本語ネイティブ × フロンティア品質）に構造的にド直撃
- ・ ￥1億は普通の契約サイズ／日本法人と契約する／公募・RFP・コンソーシアムという入口がある

￥1億までの階段

段	やること	規模	目安
1（今）	個人事業主でソロの有料契約・実績作り	～数十万円	～3ヶ月
2	業務委託で2～3人・継続バッチ受注	数百万円	～1年
3	法人化・10人規模のバンク	～数千万円	1～2年

4	下請け or 国策案件で¥1億	¥1億	2〜3年
---	-----------------	-----	------

チームの作り方（人を抱え込まない）

- ・ 正社員を雇うのではなく 「業務委託のバンク（名簿）」 を作る
- ・ 自分＝唯一の常設メンバー（脳）。作業者＝案件のときだけ呼ぶ外注（手）
- ・ 客に請求 → そこから外注に払う。契約が無い間は人件費ゼロ
- ・ 採用元：バイリンガルのフリーランス、元翻訳者・テープ起こし経験者、国際系大学のネットワーク、クラウドソーシングの実績者。自分のオリジナル教材で育てる

自分の役割の再定義

自分がやる（常設・1人でいい）	外注に任せる（案件ごと）
営業・契約／品質基準の設計・研修／最終QA・レビュー／プロジェクト管理	実際のアノテーション作業／一次処理

法人化の判断

- ・ 業務委託で働きながら自分の会社を持つのは原則OK（契約の競業避止・専属条項は要確認）
- ・ タイミングが命：「法人じゃないと発注できない」と相手が言った瞬間が引き金。それまで作らない
- ・ 順番：①開業届（個人事業主・無料）→ ②必要になったら合同会社（安い）→ ③拡大したら株式会社

△ ガードレール（これを破ると全部吹き飛ぶ）

- ・ 守秘義務のあるプロジェクトの具体内容・ガイドライン・事例・分類・基準を、加工しても流用しない。教材も営業資料もゼロから自分の言葉で
- ・ 現契約の競業避止・勧誘禁止を必ず確認。元同僚の引き抜きはNG。下請け自体はOKでも競合行為は要注意
- ・ 実クライアント名（ラボ名）は出さない。”a frontier AI lab” で止める
- ・ 現在の収入（床）は、副業売上が超えるまで手放さない

4. 営業ツールキット (自分用)

LinkedIn — Headline

Audio Annotation QA Lead | Speaker Diarization & Audio Captioning | Multilingual AI Training Data

LinkedIn — About

I lead quality assurance for multilingual audio and video annotation used to train and evaluate AI models.

I've spent 2+ years in AI training data – working with Outlier, Mercor, and most recently as a QA lead on a frontier AI lab's audio project, where I grew from trainer to pre-completion reviewer, post-completion reviewer, and QA lead. My work covers:

- Speaker diarization (word-level, 100ms-accurate timestamps)
- Audio captioning (music, sound effects, ambient sound, silence)
- Speaker profiling (visual, vocal, accent, emotion/delivery tagging)
- Training annotators and building review pipelines from scratch

I work to frontier-lab quality standards across multiple languages (Japanese, English).

Open to data QA contracts and annotation pipeline consulting.
kazmike.s@gmail.com

LinkedIn 申請メモ (200字以内・コールド用)

Hi [Name] – I do QA for multilingual audio annotation & diarization. 2+ yrs in AI training data, recently QA lead at a frontier AI lab. Happy to run a free sample audit on your audio.

Email — 件名&本文 (直接営業用)

Subject: Free QA audit for [Company]'s multilingual audio data

Hi [Name],

I came across [Company]'s work on multilingual voice agents. The quality of the underlying audio annotation is make-or-break for that kind of product –

and that's exactly what I do.

For the past 2+ years I've worked in AI training data, most recently as a QA lead on a frontier AI lab's multimodal audio project: speaker diarization, audio captioning, and vocal/emotion tagging across multiple languages (including Japanese and English).

I'd be glad to run a free QA audit on a small sample of your audio data – no strings attached. You'd get a concrete report of what I catch, and you can decide if it's useful from there.

Would you be open to that?

Best,
Kazuma Sasaki
linkedin.com/in/kazumasasaki · kazmike.s@gmail.com

Sample QA Report — 雛形（無料監査の成果物）

Sample QA Audit – [Client]

Reviewer: Kazuma Sasaki Batch: [id] Items: [n] Date: [date]

Languages: [Japanese, English]

SUMMARY

Items reviewed / Pass / Needs fixes / Major / Minor

Headline takeaway: [the single highest-impact fix for the whole batch]

FINDINGS (per item)

Item [id] – [timestamp]

Layer: Transcription / Timestamp / Speaker / Description / Tags

Severity: Major / Minor

Issue: [what is wrong]

Fix: [the specific correction]

RECURRING PATTERNS

1. [Pattern] – ~[n] items. [Why it matters + rule to apply]

RECOMMENDATIONS

- [Process / guideline change that prevents this class of error]

ターゲットリスト

会社 / 領域	狙う相手	メモ
Samora AI（多言語ボイスエージェント・YC W26）	Kartik Sawhney (CEO) / Vineeth Kumar / Shakul Sonker	17人規模・創業者が直接読む。DM送信済み

PyannoteAI（話者分離AI・仏）	CTO / Founder	diarizationがコア＝品質が命
Mundo AI（多言語学習データ）	Founder / Head of Data	競合かつ協業先候補
国産AI / LLM	Sakana AI, Preferred Networks, rinna, NTT, SoftBank	日本語データ品質に課題
国策AIデータ事業	GENIAC / NEDO 系プログラム	単発¥1億の本命ルート

次のアクション

- ・ 現契約（競業避止・勧誘禁止）の確認 ← 下請けルートの可否を決める
- ・ ソロで最初の有料案件を「継続バッチレビュー」の形で取る
- ・ PyannoteAI / Mundo AI へDM
- ・ 国策AIデータ事業の公募状況を調べる

© Kazuma Sasaki — 個人用資料。本書の内容はすべて独自に作成したもので、守秘義務のある第三者プロジェクトの機密情報を含みません。